# **Tugas 4 Big Data**



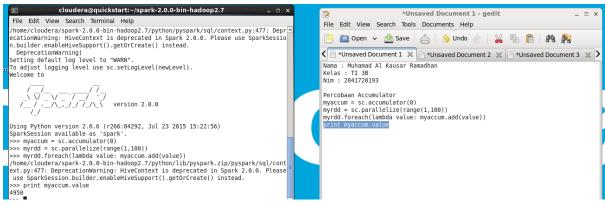
Created By:

[Muhamad Al Kausar Ramadhan]

[2041720193]

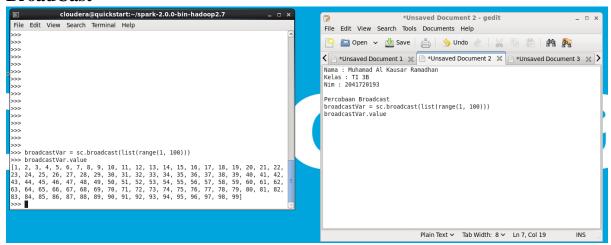
# D4 TEKNIK INFORMATIKA TEKNOLOGI INFORMASI POLITEKNIK NEGERI MALANG 2023

#### 1. Accumulator



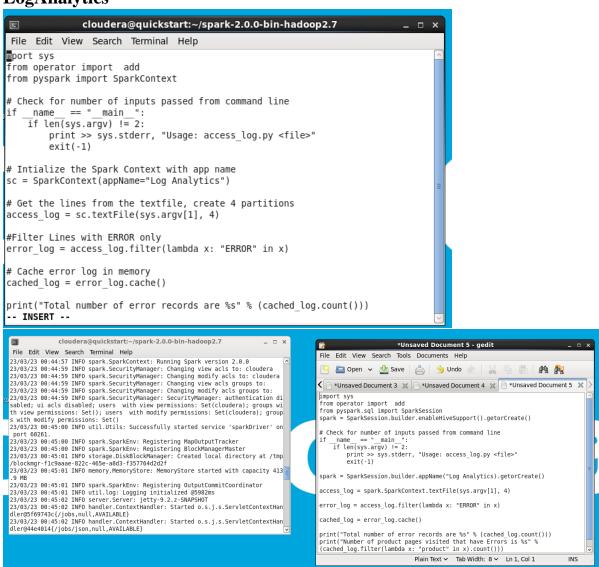
**Penjelasan:** Kode program di atas menggunakan Apache Spark untuk melakukan parallel processing pada sebuah RDD (Resilient Distributed Dataset) dan menghitung jumlah total dari nilai-nilai dalam RDD tersebut.

#### 2. BroadCast



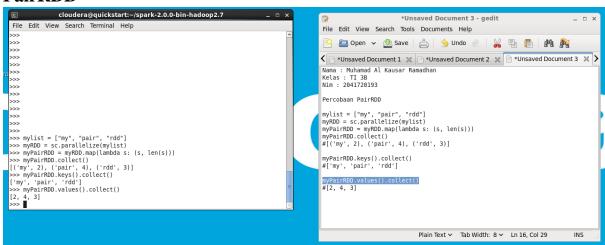
**Penjelasan:** Kode program di atas menggunakan Apache Spark untuk membuat sebuah objek broadcast variable pada RDD (Resilient Distributed Dataset) yang berisi list nilai dari 1 hingga 99. Broadcast variable merupakan variabel yang dapat dibaca oleh semua worker nodes pada Spark cluster, dan digunakan untuk mengirimkan nilai yang sama ke setiap worker node secara efisien.

### 3. LogAnalytics



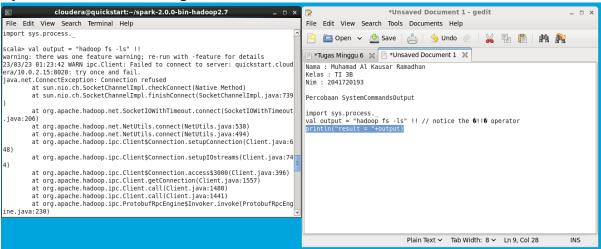
**Penjelasan:** Kode program di atas merupakan program untuk melakukan analisis terhadap file log akses. Program ini menggunakan Apache Spark untuk membaca file log akses dan melakukan operasi pemrosesan data pada RDD

#### 4. PairRDD

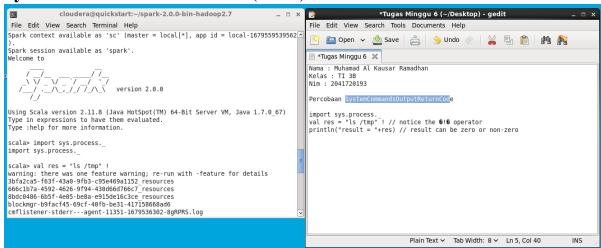


**Penjelasan:** Kode program di atas adalah contoh penggunaan Apache Spark menggunakan Python. Kode program tersebut melakukan transformasi data dari list ke dalam RDD (Resilient Distributed Dataset), lalu melakukan mapping untuk membuat pasangan nilai (key, value) yang terdiri dari kata dan panjang kata. Selanjutnya, kode program tersebut mengekstrak nilai kunci dan nilai nilai dari pasangan nilai (key, value) menggunakan method keys() dan values(), kemudian nilai-nilai tersebut dikumpulkan dengan menggunakan method collect().

## 5. SystemCommandsOutput (Scala)

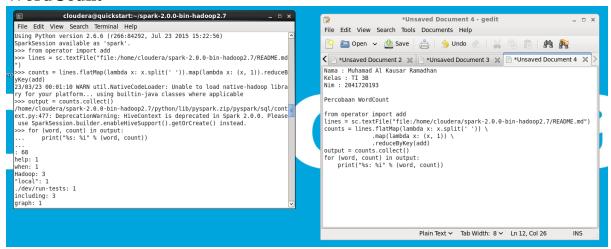


6. SystemCommandsReturnCode(Scala)



# 7. Understanding RDDs

#### 8. WordCount



**Penjelasan:** Kode program di atas adalah contoh penggunaan Apache Spark menggunakan Python untuk menghitung jumlah kemunculan setiap kata pada sebuah file teks (dalam contoh ini menggunakan file README.md yang ada di folder home/cloudera/spark-2.0.0-bin-hadoop2.7). Kode program tersebut membaca file teks dari path tertentu, melakukan transformasi data dalam RDD (Resilient Distributed Dataset) dengan melakukan pemecahan string